

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное автономное образовательное
учреждение высшего образования

«Южно-Уральский государственный университет
(национальный исследовательский университет)»

Институт естественных и точных наук

Кафедра системного программирования

ОТЧЕТ

о выполнении практической работы №2

по дисциплине

«Основы интеллектуального анализа данных»

Проверил:

доцент кафедры СП

_____ Б.А. Марков

Автор работы:

студент группы ЕТ-401

_____ М.А. Одинцов

Челябинск, 2026 г.

ОГЛАВЛЕНИЕ

1. ФОРМУЛИРОВКА ЗАДАНИЯ	3
2. ИСХОДНЫЙ КОД	3
3. ОПИСАНИЕ РЕАЛИЗАЦИИ	3
4. РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТОВ	5
5. ПОЯСНЕНИЯ К ПОЛУЧЕННЫМ РЕЗУЛЬТАТАМ	6
6. ВЫВОДЫ	8

1. ФОРМУЛИРОВКА ЗАДАНИЯ

Доработать программу поиска частых наборов, чтобы она также выполняла поиск ассоциативных правил. Список результирующих правил должен выдаваться в удобочитаемом виде (антецедент → консеквент) с указанием поддержки и достоверности каждого правила. Дополнительными параметрами программы являются порог достоверности и способ упорядочивания результирующего списка (по убыванию значения поддержки или лексикографический).

Провести эксперименты на наборе данных из задания 1 (baskets.csv — сведения о покупках в супермаркете), зафиксировав пороговое значение поддержки и варьируя пороговое значение достоверности от 70% до 95% с шагом 5%. Выполнить визуализацию результатов в виде диаграмм: сравнение быстродействия поиска правил при изменяемом пороге достоверности; общее количество найденных правил при изменяемом пороге достоверности. Подготовить список правил, в которых антецедент и консеквент суммарно включают в себя не более семи объектов, и проанализировать содержательный смысл полученного результата.

2. ИСХОДНЫЙ КОД

Исходный код (Kotlin), набор данных baskets.csv (7501 покупательская корзина, 115 наименований товаров), результаты экспериментов и диаграммы доступны по ссылке: <https://github.com/MaximOdincov/apriori-lab1>. Программа практической работы №2 — файл src/lab2/EclatLab.kt; списки правил по порогам достоверности — каталог results2/, диаграммы — charts_rules.html.

3. ОПИСАНИЕ РЕАЛИЗАЦИИ

Программа реализована на языке Kotlin без внешних библиотек. Поиск частых наборов выполнен алгоритмом ECLAT (Equivalence CLAss Transformation). В отличие от Apriori, ECLAT работает с «вертикальным» представлением данных: каждому товару сопоставляется tidset — множество номеров корзин, в которых он встречается. Поддержка любого набора равна размеру пересечения tidset'ов его товаров, поэтому база

сканируется только один раз при построении вертикального представления, а дальнейший поиск — обход в глубину: текущий набор расширяется очередным товаром, и пересечение tidset'ов меньше порога отсекает ветвь (все надмножества нечастого набора также нечастые — то же антимонотонное свойство, что и у Apriori).

Ассоциативные правила строятся разбиением каждого частого набора на антецедент X и консеквент Y (перебор всех разбиений битовой маской). Для каждого правила вычисляются: поддержка $\text{support} = \text{supp}(X \sqcup Y)/N$, достоверность $\text{confidence} = \text{supp}(X \sqcup Y)/\text{supp}(X)$, а также $\text{lift} = \text{confidence}/P(Y)$. Правила проходят фильтры по порогу достоверности и по суммарному размеру $|X| + |Y| \leq 7$ и выводятся в виде «{антецедент} → {консеквент}» с указанием поддержки и достоверности. Параметры программы: порог поддержки, порог достоверности, способ упорядочивания списка правил (по убыванию поддержки или лексикографический), предельный размер правила.

Выбор зафиксированного порога поддержки: при предложенном в примере значении 10% на наборе baskets.csv не выживает ни одна пара товаров (показано в экспериментах задания 1), следовательно, правила построить невозможно. Порог поддержки зафиксирован на уровне 0,2% (16 транзакций) — минимальном, при котором на данном наборе существуют правила с достоверностью $\geq 70\%$. При этом пороге ECLAT находит 2492 частых набора (111 одиночек, 1144 пары, 1082 тройки, 155 четвёрок) примерно за 190 мс.


4. РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТОВ

Порог поддержки зафиксирован (0,2%), порог достоверности варьировался от 70% до 95% с шагом 5%. Результаты сведены в таблицу 1.

Таблица 1 - Результаты эксперимента

Порог	Найдено правил	Время поиска правил
70%	13	≈ 35 мс
75%	6	≈ 17 мс
80%	3	≈ 17 мс
85%	0	≈ 18 мс
90%	0	≈ 17 мс
95%	0	≈ 13 мс

1. Быстродействие поиска правил при изменении порога достоверности



2. Общее количество найденных правил при изменении порога достоверности




Рисунок 1 – Результаты визуализации экспериментов: (а) время поиска правил при изменении порога достоверности; (б) общее количество найденных правил при изменении порога достоверности.

5. ПОЯСНЕНИЯ К ПОЛУЧЕННЫМ РЕЗУЛЬТАТАМ

Количество правил от порога достоверности. С ростом порога число правил быстро убывает: 13 правил при 70%, 6 — при 75%, 3 — при 80% и ни одного при 85–95%. Это ожидаемо: достоверность 70% означает, что не

менее чем в 7 корзинах из 10 с антецедентом присутствует и консеквент; в реальных покупательских корзинах товары почти независимы, и столь сильные условные зависимости возникают только у редких тематических комбинаций (поддержка найденных правил — 0,2–0,4%). Все найденные правила состоят из 3–4 объектов, то есть ограничение $|X| + |Y| \leq 7$ отсекает лишь потенциально трудноинтерпретируемые длинные комбинации, не влияя на содержательные результаты. Полный список правил приведён в таблице 2.

Быстродействие. Время поиска правил (генерация разбиений и фильтрация по порогу) составило 13–35 мс и практически не зависит от порога достоверности: перебор разбиений частых наборов выполняется всегда полностью, а порог лишь отсеивает часть результатов; наблюдаемый разброс связан с шумом измерений. От порога достоверности не зависит и этап поиска частых наборов ECLAT (≈ 190 мс), определяемый исключительно порогом поддержки, — поэтому общее время получения правил практически константно вдоль всей оси порогов. Для сравнения: все 2492 частых набора ECLAT находит без единого повторного сканирования базы (за счёт пересечений *tidset*'ов), тогда как Apriori на каждом уровне перечитывает все транзакции.

Содержательный смысл найденных правил. Консеквентами найденных правил выступают всего два товара: минеральная вода (9 правил из 13) и макароны (4 из 13) — товары-«магниты» с максимальной базовой частотой, которые покупатели добавляют поверх содержательного набора. Антецеденты, напротив, образуют осмысленные заготовки блюд: {блинчики, говяжий фарш, рис} или {замороженные овощи, оливковое масло, помидоры} → макароны — комплект для пасты или гарнира; {грибной соус, эскалоп} → макароны — классическое сочетание «мясо + гарнир»; {индейка, красное вино} → минеральная вода — праздничный ужин. Значения lift (2,9–4,5) подтверждают, что совместные покупки не случайны: вероятность консеквента в корзине с антецедентом в 3–4,5 раза выше средней. Практическое применение: размещение базовых товаров рядом с ингредиентами типовых блюд, рекомендации «добавьте к заказу» и комплектация промо-наборов.

Таблица 2 - Список правил с $|антецедент| + |консеквент| \leq 7$ и достоверностью $\geq 70\%$

Антецедент $\rightarrow$ консеквент	Размер	Support	Confidence	Lift
{грибной соус, эскалоп} $\rightarrow$ {макароны}	3	0,43%	74,4%	3,96
{замороженные овощи, молоко, суп} $\rightarrow$ {минеральная вода}	4	0,31%	76,7%	3,22
{макароны, растительное масло, яйца} $\rightarrow$ {минеральная вода}	4	0,31%	71,9%	3,02
{замороженные овощи, оливковое масло, шоколад} $\rightarrow$ {минеральная вода}	4	0,28%	70,0%	2,94
{молоко, оливковое масло, яйца} $\rightarrow$ {минеральная вода}	4	0,27%	71,4%	3,00
{говяжий фарш, замороженные овощи, креветки} $\rightarrow$ {макароны}	4	0,25%	79,2%	4,21
{макароны, обезжиренное молоко} $\rightarrow$ {минеральная вода}	3	0,25%	73,1%	3,07
{блинчики, макароны, растительное масло} $\rightarrow$ {минеральная вода}	4	0,23%	73,9%	3,10
{блинчики, макароны, суп} $\rightarrow$ {минеральная вода}	4	0,23%	77,3%	3,24
{блинчики, говяжий фарш, рис} $\rightarrow$ {минеральная вода}	4	0,21%	84,2%	3,53
{замороженные овощи, оливковое масло, помидоры} $\rightarrow$ {макароны}	4	0,21%	84,2%	4,48
{индейка, красное вино} $\rightarrow$ {минеральная вода}	3	0,21%	72,7%	3,05
{молоко, помидоры, рис} $\rightarrow$ {макароны}	4	0,21%	80,0%	4,26

6. ВЫВОДЫ

Программа доработана: поверх поиска частых наборов реализован поиск ассоциативных правил с выводом в виде «антецедент $\rightarrow$ консеквент», указанием поддержки и достоверности каждого правила, параметрами порога достоверности и способа упорядочивания; поиск наборов переведён на алгоритм ECLAT с вертикальным представлением данных. Проведены эксперименты на baskets.csv при зафиксированной поддержке 0,2% и порогах достоверности 70–95%: показано, что количество правил резко убывает с ростом порога (13 $\rightarrow$ 0), а время поиска от порога достоверности практически не зависит. Найденные правила с $|X| + |Y| \leq 7$ имеют ясное

содержательное толкование (комплекты продуктов для типовых блюд с высокочастотными товарами-«магнитами» в качестве консеквентов) и подтверждаются высокими значениями lift.